

UNIVERSIDADE SÃO JUDAS TADEU — USJT
CIÊNCIA DA COMPUTAÇÃO / ANÁLISE E DESENVOLVIMENTO DE SISTEMAS
DISCIPLINA: MATEMÁTICA APLICADA — TRABALHO A3

Matemáticas Aplicadas no Desenvolvimento de Software

Documentação técnica dos modelos matemáticos implementados

TECH WEAR — E-Commerce de Roupas Esportivas

Integrantes do Grupo

Victor Cajaíba de Oliveira

São Paulo, abril de 2026

Sumário

1.	Introdução ao Projeto Tech Wear	2
2.	Matemática Aplicada I — Cálculo de Frete (Tabela ANTT)	3
3.	Matemática Aplicada II — Previsão de Estoque (Regressão Linear)	6
4.	Matemática Aplicada III — Similaridade de Cor por Distância Euclidiana (HEX/RGB)	9
5.	Conclusão	12

SEÇÃO 1

Introdução ao Projeto Tech Wear

O **Tech Wear** é uma plataforma de e-commerce especializada em roupas esportivas, desenvolvida como projeto acadêmico para a disciplina de Matemática Aplicada da Universidade São Judas Tadeu (USJT). A aplicação foi construída utilizando tecnologias web front-end (HTML, CSS e JavaScript puro) com persistência de dados via `localStorage`, e um módulo de backend em Python com FastAPI para processamento de imagens através dos modelos YOLO e CLIP.

O objetivo do projeto é demonstrar, de forma prática, como conceitos matemáticos fundamentais são aplicados em sistemas de software reais. Foram selecionadas três áreas de aplicação distintas, cada uma com formulação matemática própria:

1. **Cálculo de Frete** — uso da tabela tarifária ANTT com fórmulas de custo logístico, impostos e tempo de entrega.
2. **Previsão de Estoque** — aplicação de regressão linear simples para projetar demanda futura e identificar risco de ruptura de estoque.
3. **Similaridade de Cor por Distância Euclidiana** — uso da geometria do espaço RGB e do algoritmo K-Means para recomendar produtos visualmente semelhantes a uma foto enviada pelo usuário.

As seções seguintes detalham cada uma dessas matemáticas: seu contexto de uso dentro do sistema, as fórmulas empregadas, os parâmetros utilizados e exemplos numéricos ilustrativos.

SEÇÃO 2 — MATEMÁTICA APLICADA I

Cálculo de Frete — Tabela ANTT

2.1 Contexto de Uso no Sistema

O módulo de frete do Tech Wear implementa a metodologia tarifária da **Agência Nacional de Transportes Terrestres (ANTT)**, baseada na resolução que define o piso mínimo para o transporte rodoviário de cargas. O cálculo está presente em dois pontos do sistema:

- **Checkout do cliente (wallet.html):** ao informar o CEP, o sistema busca automaticamente a UF de destino via BrasilAPI, estima a distância rodoviária a partir de São Paulo e apresenta duas opções de entrega (Expressa por motoboy / Padrão por van).
- **Painel Operacional (frete.html):** ferramenta administrativa completa, que permite simular o custo detalhado de qualquer pedido, com breakdown de impostos, pedágios, tempo de entrega e score de prioridade.

2.2 Parâmetros Fixos da ANTT

Parâmetro	Símbolo	Valor	Descrição
Taxa ANTT (R\$/km)	τ	R\$ 3,8866/km	Custo base por quilômetro rodado
Volume base consolidado	V_{base}	2,64 m³	Volume de referência para rateio de frete
Taxa de descarga	T_{desc}	R\$ 436,39	Custo fixo por operação de descarga
Pedágio	P	R\$ 20,00/100km	Custo de pedágios por faixa de 100 km
Margem de segurança	MS	1,3015 (30,15%)	Margem comercial aplicada ao frete
PIS	α_{PIS}	1,65%	Incide sobre o valor do motorista
COFINS	α_{COF}	7,60%	Incide sobre o valor do motorista

2.3 Fórmulas do Cálculo de Frete

ETAPA 1 — FRETE BASE ANTT

$$F_{ANTT} = D \times \tau$$

Onde D = distância rodoviária em km; τ = R\$ 3,8866/km

ETAPA 2 — VALOR DO MOTORISTA E IMPOSTOS

$$V_{\text{motor}} = F_{\text{ANTT}} / 2$$

$$\text{PIS} = V_{\text{motor}} \times 0,0165$$

$$\text{COFINS} = V_{\text{motor}} \times 0,0760$$

ICMS = varia por UF de destino (0% a 17%)

$$F_{\text{imp}} = F_{\text{ANTT}} + \text{PIS} + \text{COFINS} + \text{ICMS}$$

ETAPA 3 — PEDÁGIO

$$P = \lfloor D / 100 \rfloor \times 20$$

Função piso: uma cobrança de R\$20 para cada 100 km percorridos

ETAPA 4 — FRETE FINAL (COM MARGEM DE SEGURANÇA)

$$F_{\text{final}} = (F_{\text{imp}} \times MS) + P + T_{\text{desc}}$$

$MS = 1,3015$ (margem comercial de 30,15%)

ETAPA 5 — RATEIO POR VOLUME DO PEDIDO

Como o frete foi calculado para o caminhão consolidado (2,64 m³), o custo é rateado proporcionalmente ao volume do pedido:

$$F_{\text{pedido}} = F_{\text{final}} \times (V_{\text{pedido}} / V_{\text{base}})$$

V_{pedido} = soma dos volumes de cada item do carrinho

$V_{\text{base}} = 2,64 \text{ m}^3$ (volume de referência da van)

2.4 Fórmula de Tempo de Entrega

$$T_{\text{total}} = (D \times K_{\text{rota}}) / (v \times f_h) + n \times t_s + T_{\text{prep}} + T_{\text{margem}}$$

D = distância | K_{rota} = fator de tortuosidade da rota

v = velocidade média do veículo | f_h = fator de eficiência horária

n = pedidos na fila | t_s = tempo médio por parada

Veículo	v (km/h)	f_h	K_{rota}	t_s (min)
 Motoboy	40	0,9	1,1	4

Veículo	v (km/h)	f _h	K _{rota}	t _s (min)
 Van / Fiorino	50	0,7	1,3	7

2.5 Score de Prioridade (S_p)

O painel operacional permite calcular a prioridade de despacho de um pedido com base em dois critérios ponderados:

S_p = (Urgência × 0,6) + (Densidade × 0,4)

Urgência: nota 0-10 do cliente | Densidade: razão massa/volume do pedido

Ambos normalizados para escala 0-1 antes da ponderação

Exemplo numérico: Pedido para Curitiba/PR (D = 408 km). F_{ANTT} = 408 × 3,8866 = R\$ 1.585,73 | V_{motor} = R\$ 792,87 | PIS = R\$ 13,08 | COFINS = R\$ 60,26 | Pedágio = [408/100] × 20 = 4 × 20 = R\$ 80,00 | F_{final} = (1.585,73 + 13,08 + 60,26) × 1,3015 + 80 + 436,39 = **R\$ 2.793,52** | Para pedido de 0,02 m³: F_{pedido} = 2.793,52 × (0,02/2,64) = **R\$ 21,16**

SEÇÃO 3 — MATEMÁTICA APLICADA II

Previsão de Estoque — Regressão Linear

3.1 Contexto de Uso no Sistema

O **Dashboard de Analytics (dashboard.html)** do Tech Wear implementa dois modelos preditivos baseados em regressão linear: um para prever a **receita do próximo mês** e outro para identificar **risco de ruptura de estoque** por produto.

A regressão linear é o modelo mais adequado para séries temporais curtas (6 a 12 meses de histórico), onde se deseja uma tendência de crescimento ou queda sem complexidade computacional excessiva, o que é ideal para um sistema front-end executado no navegador.

3.2 Regressão Linear Simples

Dada uma série temporal de valores mensais $y_0, y_1, \dots, y_{n-1}$ (receita ou quantidade de pedidos), a regressão linear determina a reta de melhor ajuste $\hat{y} = m \cdot x + b$, onde:

$$m = (n \cdot \sum XY - \sum X \cdot \sum Y) / (n \cdot \sum X^2 - (\sum X)^2)$$

$$b = (\sum Y - m \cdot \sum X) / n$$

n = número de meses | x_i = índice do mês (0, 1, 2, ...) | y_i = valor observado

3.3 Projeção do Próximo Mês

Para projetar o valor do mês seguinte (índice n), aplica-se a reta calculada no ponto além da série:

$$\hat{y}_n = m \cdot n + b$$

Valor mínimo = 0 (garante que não seja negativo)

3.4 Coeficiente de Determinação R^2

O R^2 (R-quadrado) mede a qualidade do ajuste da reta aos dados históricos. Varia de 0 a 1: quanto mais próximo de 1, mais confiável é a previsão.

$$R^2 = 1 - (SS_{\text{res}} / SS_{\text{tot}})$$

$SS_{\text{res}} = \sum (y_i - \hat{y}_i)^2$ ← soma dos resíduos ao quadrado

$$SS_{\text{tot}} = \sum (y_i - \bar{y})^2 \leftarrow \text{variância total em torno da média}$$

$\bar{y}$ = média dos valores observados

Faixa de R²	Classificação no sistema	Interpretação
0,75 — 1,00	Alta confiança	Tendência clara e consistente
0,40 — 0,74	Média confiança	Crescimento com oscilações moderadas
0,00 — 0,39	Baixa confiança	Série instável; previsão é estimativa

3.5 Previsão de Ruptura de Estoque

Para cada produto cadastrado, o sistema calcula a **velocidade de venda** com base nos últimos 30 dias e projeta o estoque futuro:

$$vel_{30} = \sum \text{unidades vendidas nos últimos 30 dias}$$
$$vel_{\text{dia}} = vel_{30} / 30$$
$$dias_{\text{restantes}} = \lfloor \text{estoque}_{\text{atual}} / vel_{\text{dia}} \rfloor$$
$$estoque_{30d} = \text{estoque}_{\text{atual}} - vel_{30}$$
$$\text{reposição} = \max(0, \lceil vel_{30} \times 1,2 \rceil - \text{estoque}_{\text{atual}})$$

Fator 1,2 = margem de segurança de 20% sobre a demanda prevista

3.6 Critérios de Alerta


Condição	Status	Ação sugerida
$vel_{30} = 0$	Sem movimento	Produto sem giro; avaliar descontinuação
$dias_{\text{restantes}} \leq 15$	Crítico	Reposição imediata necessária
$dias_{\text{restantes}} \leq 45$	Atenção	Planejar reposição em breve
$dias_{\text{restantes}} > 45$	OK	Estoque adequado para o período

Exemplo numérico: Produto "Camiseta Performance UV" com estoque = 40 unidades. Nas últimas 30 dias foram vendidas 12 unidades. $vel_{\text{dia}} = 12/30 = 0,4$ un/dia. $dias_{\text{restantes}} = \lfloor 40/0,4 \rfloor = 100$ dias → Status: **OK**. $\text{Reposição} = \max(0, \lceil 12 \times 1,2 \rceil - 40) = \max(0, 15 - 40) = 0$ (não precisa repor).

SEÇÃO 4 — MATEMÁTICA APLICADA III

Similaridade de Cor — Distância Euclidiana no Espaço RGB**4.1 Contexto de Uso no Sistema**

O módulo **WearIA (wearia.html)** permite ao usuário fotografar uma roupa qualquer — do próprio guarda-roupa ou de uma vitrine — e receber recomendações de produtos do catálogo Tech Wear com cores visualmente semelhantes. Todo o processamento de cor ocorre no front-end, diretamente no navegador, sem necessidade de servidor.

**4.2 Espaço de Cores RGB**

Cada cor digital é representada por três componentes inteiros no intervalo [0, 255]: **R** (vermelho), **G** (verde) e **B** (azul). Um código hexadecimal como **#4b5320** corresponde a R=75, G=83, B=32. Esses três valores definem um ponto num **espaço tridimensional** — o cubo de cores RGB.

4.3 Extração da Cor Dominante com K-Means

Antes de comparar cores, é necessário identificar a cor dominante da roupa na imagem. O sistema aplica o algoritmo **K-Means** sobre os pixels do crop central da imagem (região onde a roupa provavelmente está), com **k = 4 clusters**:

Inicialização: selecionar k centroids iniciais espaçados uniformemente

Atribuição: para cada pixel p , atribuir ao centroid c^* mais próximo:

$$c^* = \operatorname{argmin}_c d(p, c) = \operatorname{argmin}_c \sqrt{(R_p - R_c)^2 + (G_p - G_c)^2 + (B_p - B_c)^2}$$

Atualização: recalcular cada centroid como a média dos pixels atribuídos

Repetir atribuição + atualização por no máximo 15 iterações

Após a convergência, o cluster com **maior quantidade de pixels** que não pertencem ao fundo da imagem representa a cor dominante da peça.

4.4 Distância Euclidiana no Espaço RGB

Para comparar a cor detectada na imagem com o `hex_color` de cada produto do catálogo, utiliza-se a **distância euclidiana** entre dois pontos no cubo RGB tridimensional:

$$d(A, B) = \sqrt{(R_A - R_B)^2 + (G_A - G_B)^2 + (B_A - B_B)^2}$$

$$d \in [0 ; 441,67], \text{ onde } d_{\max} = \sqrt{255^2 + 255^2 + 255^2} \approx 441,67$$

$$d = 0 \rightarrow \text{cores idênticas} \mid d = 441,67 \rightarrow \text{cores mais distantes possíveis (preto x branco)}$$

4.5 Score de Similaridade Normalizado

A distância é convertida num score de similaridade entre 0 e 1, onde 1 significa cores idênticas:

$$\text{similaridade}(A, B) = 1 - d(A, B) / d_{\max}$$

$$d_{\max} = \sqrt{255^2 + 255^2 + 255^2} \approx 441,67$$

O sistema define um **limiar mínimo de 0,60** (60% de similaridade). Produtos com score abaixo desse limiar são descartados e o usuário recebe a mensagem "não encontramos nada parecido". Os 3 produtos com maior score são exibidos como recomendações principais.

Exemplo de par de cores	RGB A	RGB B	d(A,B)	Similaridade
Preto x Preto	(0,0,0)	(0,0,0)	0,00	100,0%
Preto (#1a1a1a) x Verde Militar (#4b5320)	(26,26,26)	(75,83,32)	77,2	82,5%
Cinza (#808080) x Azul Marinho (#1b2a4a)	(128,128,128)	(27,42,74)	152,8	65,4%
Preto x Branco	(0,0,0)	(255,255,255)	441,67	0,0%

4.6 Subtração do Fundo

Para evitar que a cor do fundo da imagem (parede, chão) interfira na detecção, o sistema aplica um **limiar de separação** de 60 unidades de distância euclidiana:

$$\text{pixel é "da roupa" se: } d(\text{pixel}_{\text{RGB}}, \text{fundo}_{\text{RGB}}) > 60$$

$$\text{fundo}_{\text{RGB}} \text{ é estimado pela média dos pixels das bordas da imagem (margem de 5px)}$$

Somente os pixels classificados como "da roupa" são passados ao algoritmo K-Means, garantindo que a cor dominante detectada pertença efetivamente à peça de vestuário, não ao ambiente.

Exemplo numérico: Usuário envia foto de uma jaqueta verde-militar. K-Means detecta cor dominante: RGB = (71, 79, 28) → HEX = **#474f1c**. Produto "Jaqueta Windbreaker" tem **hex_color = #4b5320** → RGB = (75, 83, 32). $d = \sqrt{[(71-75)^2 + (79-83)^2 + (28-32)^2]} = \sqrt{16+16+16} = \sqrt{48} \approx 6,93$. similaridade = $1 - 6,93/441,67 = \mathbf{98,4\%}$ → produto exibido como recomendação #1.

SEÇÃO 5

Conclusão

O projeto Tech Wear demonstrou que a matemática aplicada não se limita a cálculos abstratos: ela está presente em decisões de negócio cotidianas, como calcular o custo justo de uma entrega, antecipar a falta de um produto em estoque ou identificar visualmente uma peça de roupa.

Módulo	Área Matemática	Conceitos Centrais	Localização no Sistema
Cálculo de Frete	Matemática Financeira / Logística	Tarifação ANTT, impostos (PIS/COFINS/ICMS), função piso, rateio por volume, ponderação	wallet.html · frete.html
Previsão de Estoque	Estatística / Análise de Dados	Regressão linear simples, mínimos quadrados, coeficiente R^2 , velocidade de venda	dashboard.html
Similaridade de Cor	Geometria Analítica / Álgebra Linear	Espaço vetorial RGB, distância euclidiana, K-Means, normalização, limiar de decisão	wearia.html · js/wearia.js

A integração dessas três matemáticas num único sistema web demonstra a versatilidade dos conceitos fundamentais de cálculo, estatística e geometria quando aplicados a problemas reais de engenharia de software.